

Evaluasi Sistem Pendeteksi Intrusi Berbasis Anomali dengan *N-Gram* dan *Incremental Learning*

I Made Agus Adi Wirawan, Royyana Muslim Ijtihadie, dan Baskoro Adi Pratomo
Jurusan Teknik Informatika, Fakultas Teknologi Informasi
Institut Teknologi Sepuluh Nopember (ITS)
Jl. Arief Rahman Hakim, Surabaya 60111 Indonesia
e-mail: {roy, baskoro}@if.its.ac.id

Abstrak—Keberadaan teknologi informasi yang terus berkembang dengan pesat menjadikan kebutuhan akan penggunaannya semakin hari semakin meningkat. Transaksi data melalui internet telah menjadi kebutuhan wajib hampir dari semua perangkat lunak yang ada saat ini. Perangkat lunak seperti media social, colud server, online game, aplikasi layanan pemerintah, aplikasi pengontrol suatu tempat secara remote, dsb. Tentu dengan berbagai macam penggunaan internet tersebut dibutuhkan metode untuk mengamankan jaringannya.

Sistem pendeteksi intrusi atau yang pada umumnya disebut IDS (*Intrusion Detection System*) merupakan solusi untuk mengamankan suatu jaringan. Sistem ini nantinya bertugas untuk menentukan apakah suatu paket merupakan bentuk serangan atau paket biasa sesuai dengan kondisi tertentu. Saat ini telah banyak dikembangkan aplikasi IDS (*Intrusion Detection System*), namun sebagian besar yang dikembangkan berbasis *signature* atau menggunakan *rule*, dan sebagian kecil menggunakan anomali. Anomali adalah suatu metode untuk mencari penyimpangan dalam sebuah data.

Pada aplikasi ini konsep IDS yang diterapkan adalah IDS berbasis anomali dimana analisis data yang dilakukan terdapat pada informasi paket data yang dikirimkan. Pada tugas akhir ini menggunakan dua metode, yaitu metode *n-gram* yang digunakan untuk menghitung distribusi byte karakter pada paket data sedangkan metode *malanobis distance* digunakan untuk menghitung jarak antara paket data normal dan paket data yang berupa intrusi.

Metode *malanobis distance* dapat membedakan paket data yang normal dan paket data yang berupa intrusi dengan menghitung rata-rata dan standar deviasi dari paket data.

Kata Kunci—*N-Gram*, Mahalanobis Distance, Incremental Learning.

I. PENDAHULUAN

SEMAKIN pesatnya perkembangan teknologi informasi memudahkan orang-orang untuk saling tukar menukar data baik melalui internet maupun intranet. Tentunya dengan mudahnya berbagi data itulah sangat memungkinkan terjadinya serangan terhadap data tersebut terutama melalui jaringan komputer. Sistem pendeteksi intrusi atau yang pada umumnya disebut IDS (*Intrusion Detection System*) [1] merupakan senjata utama untuk mengamankan suatu jaringan dimana sistem ini nantinya bertugas untuk mengidentifikasi dan mencatat apakah suatu paket data tersebut merupakan bentuk serangan atau paket data biasa.

Saat ini telah banyak dikembangkan aplikasi IDS (*Intrusion Detection System*), namun sebagian besar yang dikembangkan berbasis *signature* atau menggunakan *rule*, dan sebagian kecil menggunakan anomali. Anomali pada dasarnya adalah pencarian data yang menyimpang dari sekumpulan data normal. IDS yang berbasis pada anomali [2] bersifat lebih fleksibel, karena dapat mengenali pola serangan baru tanpa harus memperbaharui basis data pola serangan. IDS yang berbasis pada anomali memiliki sebuah kecerdasan buatan yang mampu mendeteksi dan mengenali sebuah serangan. IDS yang berbasis anomali menggabungkan metode analisis dan statistik untuk mengenali penyimpangan tersebut. Kelemahan dari metode ini adalah kemungkinan salah identifikasi pada data yang diolah.

Diperlukan sebuah sistem deteksi intrusi untuk membedakan paket data normal dan paket data yang berupa intrusi dimana nantinya sistem deteksi intrusi tersebut akan menggunakan gabungan metode analisis dan statistik yang berfungsi mengenali perbedaan paket data normal maupun paket data berupa intrusi. Selain itu, sistem deteksi intrusi juga dapat mempelajari paket data normal yang baru untuk memperbarui data *training*.

Metode *n-gram* dapat digunakan untuk membuat model paket data yang sederhana dan cepat untuk dihitung, khususnya penghitungan distribusi karakter pada suatu paket data. *N-Gram* merupakan metode yang paling efisien dan efektif dalam membuat model dari suatu paket data.

Metode *malanobis distance* berguna untuk membedakan paket-paket data berdasarkan anomali yang terjadi. Sedangkan untuk dapat mempelajari paket data normal yang baru digunakan metode *incremental learning*, dimana metode ini nantinya memperbaharui rata-rata dan standar deviasi dari model paket data yang ada pada data *training*.

Artikel ini menggunakan artikel [3] sebagai acuan mengimplementasikan metode *malanobis distance* untuk mengklasifikasikan paket data dan metode *n-gram* untuk memodelkan paket data. Dan pada artikel ini membahas evaluasi dari penambahan proses *incremental learning* pada pendeteksian intrusi berbasis anomali. Apakah penambahan proses *incremental learning* dapat meningkatkan akurasi pendeteksian intrusi atau tidak.

II. DESAIN DAN PERANCANGAN

A. Anomaly Based Intrusion Detection System

Sistem deteksi intrusi berbasis *Anomaly* pada dasarnya adalah mencari sebuah data yang menyimpang dari sekumpulan data normal. IDS yang berbasis *anomaly* menggabungkan metode analisis dan statistik untuk mengenali penyimpangan tersebut [2]. IDS yang berbasis pada *anomaly* bersifat lebih fleksibel, karena dapat mengenali pola serangan baru tanpa harus memperbaharui basis data pola serangan. IDS yang berbasis pada *anomaly* memiliki sebuah kecerdasan buatan yang mampu mendeteksi dan mengenali sebuah serangan.

Kelemahan dari metode anomali ini adalah kemungkinan terjadinya salah identifikasi pada data yang diolah, juga ada kemungkinan terjadi kesalahan pada data normal yang menyebabkan aplikasi tidak dapat mengenali serangan.

B. N-Gram Payload Model

Pada dasarnya, model N-Gram [4] adalah model probabilistik yang awalnya dirancang oleh ahli matematika dari Rusia pada awal abad ke-20 dan kemudian dikembangkan untuk memprediksi *item* berikutnya dalam urutan *item*. Item bisa berupa huruf / karakter, kata, atau yang lain sesuai dengan aplikasi. Salah satunya, model *n-gram* yang berbasis kata digunakan untuk memprediksi kata berikutnya dalam urutan kata tertentu. Dalam arti bahwa sebuah *n-gram* hanyalah sebuah wadah kumpulan kata dengan masing-masing memiliki panjang *n* kata. Sebagai contoh, sebuah *n-gram* ukuran 1 disebut sebagai *unigram*; ukuran 2 sebagai *bigram*; ukuran 3 sebagai *trigram*, dan seterusnya.

Pada pembangkitan karakter, *N-gram* terdiri dari *substring* sepanjang *n* karakter dari sejumlah *string* dalam definisi lain *n-gram* adalah potongan sejumlah *n* karakter dari sebuah *string*. Metode *n-gram* ini digunakan untuk mengambil *n* potongan-potongan karakter huruf dari sebuah kata secara kontinuitas dibaca dari teks sumber sehingga akhir dari dokumen. Sebagai contoh : kata “TEXT” dapat diuraikan ke dalam beberapa *n-gram* berikut :

uni-gram : T, E, X, T
bi-gram : TE, EX, XT
tri-gram : TEX, EXT
quad-gram : TEXT, EXT_
 dan seterusnya.

Sedangkan pada pembangkitan kata, metode *n-gram* ini digunakan untuk mengambil *n* potongan kata dari sebuah rangkaian kata (kalimat, paragraf, bacaan) yang secara kontinu dibaca dari teks sumber sampai akhir dari dokumen. Sebagai contoh : kalimat “saya dapat melihat cahaya itu.” Dapat diuraikan ke dalam beberapa *n-gram* berikut :

uni-gram : saya, dapat, melihat, cahaya, itu
bi-gram : saya dapat, dapat melihat,
 melihat cahaya, cahaya itu
tri-gram : saya dapat melihat, dapat melihat
 cahaya, melihat cahaya itu_
 dan seterusnya.

Salah satu keunggulan menggunakan *n-gram* dibandingkan dengan menggunakan suatu kata utuh secara keseluruhan adalah bahwa *n-gram* tidak terlalu sensitif terhadap kesalahan penulisan yang terdapat pada suatu dokumen.

C. Simplified Mahalanobis Distance

Mahalanobis distance [5] adalah sebuah metode statistika untuk menghitung jarak antara titik P dan distribusi D. Prinsip dari Mahalanobis Distance adalah menghitung jarak di ruang multidimensional antara sebuah objek pengamatan dengan pusat dari semua pengamatan. Pada artikel ini Mahalanobis Distance digunakan untuk menghitung jarak antara distribusi *byte* karakter dari payload baru terhadap model yang ada pada data *training*. Semakin jauh jaraknya, semakin besar kemungkinan payload ini tidak normal.

Mahalanobis distance dari sebuah payload baru dapat dihitung jika sistem sudah mempunyai data *training*, untuk selanjutnya menghitung rata-rata dan standar deviasi dari model yang ada pada data *training*. Untuk menghitung rata-rata dari model yang ada pada data *training* dapat dilihat pada persamaan 1, sedangkan untuk menghitung standar deviasi dari model yang ada pada data *training* dapat dilihat pada persamaan 2. Setelah rata-rata dan standar deviasi dari model yang ada pada data *training* selesai dihitung, barulah jarak mahalanobis dari payload baru dapat dihitung dengan menggunakan persamaan 1. Format data kasar yang ada pada Mahalanobis distance dapat dilihat pada Tabel 1.

$$d(x, \bar{y}) = \sum_{i=0}^{n-1} (|x_i - \bar{y}_i| / (\bar{\sigma}_i + \alpha)) \quad (1)$$

dimana,

d = jarak mahalanobis

x_i = variable ke-i dari *payload* baru

\bar{y}_i = rata-rata variable ke-i dari model data *training*

$\bar{\sigma}_i$ = standar deviasi variable ke-i dari model data *training*

α = *smoothing factor*

	Variabel(karakteristik)						
Object	X_1	X_2	...	X_i	...	X_{p-1}	X_p
1
2
3
.
.
.
K	X_{k1}	X_{k2}	...	X_{ki}	...	$X_{k,p-1}$	$X_{k,p}$
.
.
.
N	X_{N1}	X_{N2}	...	X_{Ni}	...	$X_{N,p-1}$	$X_{N,p}$
Average	\bar{X}_1	\bar{X}_2	...	\bar{X}_i	...	\bar{X}_{p-1}	\bar{X}_p
Standar deviation	S_1	S_1	...	S_1	...	S_1	S_1

Tabel 1 Format data kasar didalam Mahalanobis Distance

Persamaan untuk mencari rata-rata, yaitu:

$$\bar{X}_i = \frac{1}{N} \sum_{k=1}^N X_{ki} \quad (2)$$

dimana,

\bar{X}_i = rata-rata variabel ke-i

N = jumlah object model

X_{ki} = nilai variabel ke-i

Persamaan untuk mencari nilai standar deviasi, yaitu:

$$S_i = \sqrt{\frac{\sum_{k=1}^N (X_{ki} - \bar{X}_i)^2}{N-1}} \quad (3)$$

dimana,

S_i = standar deviasi variabel ke- i
 X_{ki} = nilai dari variabel ke- i
 \bar{X}_i = rata-rata variabel ke- i
 N = jumlah object model

D. Incremental Learning

Incremental Learning merupakan proses untuk memperbaharui nilai rata-rata dan standar deviasi dari model yang ada pada data *training* ketika menambahkan payload baru. Proses ini diperlukan untuk meningkatkan akurasi dari setiap model ketika data sampel baru ditambahkan.

Diperlukan rata-rata dan standar deviasi dari masing-masing karakter ASCII untuk menghitung Mahalanobis *distance* versi *Incremental Learning* untuk setiap sampel baru yang dihitung. Untuk menghitung rata-rata dari sebuah karakter dapat dilihat pada persamaan 2. Selanjutnya agar dapat memperbaharui nilai rata-rata dari model yang ada pada data training, diperlukan jumlah sampel yang telah dihitung sebelumnya [6]. Untuk menghitung nilai rata-rata yang baru dapat dilihat pada persamaan 4.

Sedangkan untuk menghitung standar deviasi yang baru diperlukan rata-rata dari x_i^2 pada model sebelumnya. Untuk menghitung standar deviasi yang baru dapat dilihat pada persamaan 5.

Persamaan untuk menghitung rata-rata baru dari model yang diamati, yaitu:

$$\bar{x} = \frac{\bar{x} \times N + x_{N+1}}{N+1} = \bar{x} + \frac{x_{N+1} - \bar{x}}{N+1} \quad (4)$$

dimana,

\bar{x} = rata-rata baru
 x_{N+1} = nilai dari variabel yang baru
 N = jumlah sampel sebelumnya

Persamaan untuk menghitung standar deviasi baru dari model yang diamati, yaitu:

$$S_i = \sqrt{\frac{(n+1) \times (\sum_{i=1}^n x_i^2 + x_{n+1}^2) - (\sum_{i=1}^n x_i + x_{n+1})^2}{(n+1)n}} \quad (5)$$

dimana,

S_i = standar deviasi variabel ke- i
 x_i = nilai dari variabel ke- i
 x_{n+1} = nilai dari variabel yang baru
 n = jumlah object model

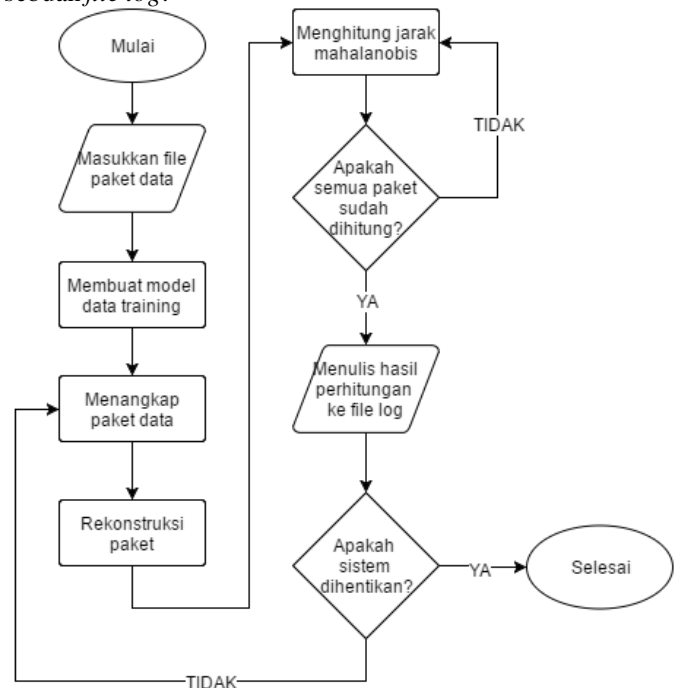
E. Alur Kerja Sistem Secara Umum

Secara umum sistem yang dibangun dengan tiga proses utama yaitu, proses training data set, proses penangkapan paket data dan proses identifikasi serangan. Alur kerja sistem secara umum dapat dilihat pada Gambar 1.

Secara lebih detail, cara kerja sistem adalah membaca file data set, membuat model data training, menyimpan model data training, menangkap paket data, memproses paket data dan membandingkan jarak mahalanobis antara paket data dengan model dan juga mengambil keputusan terhadap hasil perbandingan antara jarak mahalanobis dengan threshold. Membuat model data training adalah proses membaca file paket data dan menyimpannya pada array of object. Hanya file yang berekstensi *.cap, *.pcap, *.tcpdump dapat dibaca, dengan memanfaatkan library Jpcap [6]. Proses selanjutnya adalah menangkap paket data dari network interface dengan bantuan library Jpcap lalu menyimpannya pada array of object.

Selanjutnya adalah proses membandingkan jarak mahalanobis antara paket data dengan model data. Proses selanjutnya adalah pemanggilan fungsi Mahalanobis Distance untuk menghitung jarak mahalanobis antara paket data dengan model data training. lalu membandingkannya dengan nilai threshold yang sudah ditentukan sebelumnya. Nilai threshold setiap port memiliki besaran yang berbeda. Jika jarak mahalanobis dari paket data melebihi nilai threshold, maka paket data tersebut dapat dikategorikan sebagai paket data yang tidak normal.

Proses diatas diulangi sampai aplikasi tersebut dihentikan oleh pengguna dan menulis hasil proses perbandingan ke sebuah *file log*.



Gambar 1 Diagram alir kerja sistem secara umum

III. UJI COBA DAN EVALUASI

A. Skenario Pengujian

Pengujian yang dilakukan dibagi kedalam dua bagian, yakni:

1. Pengujian akurasi tanpa menambahkan proses *incremental learning*; dan
2. Pengujian akurasi dengan menambahkan proses *incremental learning*.

Parameter pengujian yang digunakan adalah besarnya ukuran *window*. yang dimaksud ukuran *window* disini adalah jumlah paket data yang ditangkap, jika jumlah paket data yang ditangkap sudah memenuhi ukuran *window* maka selanjutnya paket data tersebut diproses untuk mengetahui jarak mahalanobis dari setiap paket data.

B. Data Pengujian

Data uji yang nantinya akan diproses dengan metode *two fold cross validation* [8]. Metode pengujian ini digunakan karena sistem yang dibuat memiliki sifat mirip dengan aplikasi-aplikasi yang berbasis *machine learning*. Tahap *learning* yang dimaksud pada sistem ini adalah tahap untuk penentuan *threshold* pendeteksian. Berangkat dari hal ini, maka metode *two fold cross validation* dipilih sehingga kebutuhan untuk

mendapatkan *threshold* dan data uji terpenuhi. Dengan metode *two fold cross validation*, kumpulan data uji akan dibagi 2 sama banyak. Kemudian salah satu kumpulan data akan dijadikan data *training* sekaligus menentukan *threshold* dari aplikasi pendeteksian. Setelah selesai, maka kegiatan diulang kembali dengan data *training* yang sebelumnya merupakan data uji. Berikut pada Tabel 2 disajikan data uji dimana parameter pembeda antar data uji adalah besarnya ukuran *window*. *Window size* yang dimaksud adalah jumlah paket data yang ditangkap, jika jumlah paket data yang ditangkap sudah memenuhi *window size* baru paket data tersebut diproses untuk mengetahui jarak mahalanobis setiap paket. Data uji yang digunakan adalah *file* paket data hasil tangkapan paket data pada jaringan eksternal DARPA [9] pada minggu ke-4 yang berjumlah 5 *file* paket data.

Data yang akan dicatat nantinya adalah jarak mahalanobis dari paket data normal dan paket data yang berupa intrusi. Kedua variable tersebut nantinya akan diolah menjadi nilai *threshold* dengan cara menjumlahkan jarak mahalanobis terkecil dari paket data yang berupa intrusi dengan jarak mahalanobis terbesar dari paket data normal dan kemudian dibagi 2. Berikut pada persamaan 6 dijabarkan cara untuk mendapatkan nilai *threshold* pendeteksian.

$$\text{Threshold} = \frac{\min \text{ jarak serangan} + \max \text{ jarak normal}}{2} \quad (6)$$

No	Ukuran <i>window</i>	Port TCP				Port UDP
1	10000	21	23	25	80	53
2	15000	21	23	25	80	53
3	20000	21	23	25	80	53

Tabel 2 Data uji

Untuk menghitung akurasi, digunakan metode *confussion matrix* [10]. Penggunaan metode ini digunakan karena tergolong mudah untuk digunakan dan dapat menghasilkan nilai-nilai pengujian selain akurasi, seperti *true positive rate* dan *false positive rate*. *Confussion matrix* yang akan digunakan untuk pengujian akurasi adalah *confussion matrix* dengan ukuran 2x2. Berikut pada Gambar 2 ditunjukkan model *confussion matrix* beserta kemudian dijelaskan definisi masing-masing kelasnya.

		PREDICTED	
		INTRUSI	NORMAL
ACTUAL	INTRUSI	A	B
	NORMAL	C	D

Gambar 2 Model Confussion Matrix untuk pengujian

C. Hasil Pengujian

1) Pengujian akurasi tanpa menambahkan proses *incremental learning*

Dengan bekal *threshold* tersebut maka dilakukan pengujian terhadap data testing minggu ke-5, hari ke-1 tanpa proses *incremental learning*. Hasil pengujian dari 10000 paket data, yaitu terdapat 5328 *connection* yang terdiri dari 5308 paket normal dan 20 paket intrusi.

Setelah semua data diuji, maka data dapat diproses hasilnya dengan *confussion matrix*. Pada Tabel 3 disajikan klasifikasi jumlah masing-masing kelas berdasarkan pada hasil pengujian.

		PREDICTED	
		INTRUSI	NORMAL
ACTUAL	INTRUSI	6	355
	NORMAL	14	4935

Tabel 3 Confussion matrix uji coba 1

Berdasarkan pada jumlah diatas, maka didapatkan penilaian berdasarkan rumus-rumus yang terkait dengan *confussion matrix* yang disajikan pada Tabel 4.

No	Jenis Penilaian	Nilai	Persentase
1	Akurasi (AC)	0.9307	93.07%
2	<i>True positive rate</i> (TP)	0.0166	1.66%
3	<i>False negative rate</i> (FN)	0.9834	98.34%
4	<i>False positive rate</i> (FP)	0.0028	0.28%
5	<i>True negative rate</i> (TN)	0.9972	99.72%
6	Presisi (P)	0.3	30.0%

Tabel 4 Hasil penilaian percobaan 1

2) Pengujian akurasi dengan menambahkan proses *incremental learning*

Dengan bekal *threshold* tersebut maka dilakukan pengujian terhadap data testing minggu ke-5, hari ke-1 dengan tambahan proses *incremental learning*. Hasil pengujian dari 10000 paket data, yaitu terdapat 5328 *connection* yang terdiri dari 1577 paket normal dan 3751 paket intrusi.

Setelah semua data diuji, maka data dapat diproses hasilnya dengan *confussion matrix*. Pada Tabel 5 disajikan klasifikasi jumlah masing-masing kelas berdasarkan pada hasil pengujian.

		PREDICTED	
		INTRUSI	NORMAL
ACTUAL	INTRUSI	187	174
	NORMAL	3564	1403

Tabel 5 Confussion matrix uji coba 2

Berdasarkan pada jumlah diatas, maka didapatkan penilaian berdasarkan rumus-rumus yang terkait dengan *confussion matrix* yang disajikan pada Tabel 6.

No	Jenis Penilaian	Nilai	Persentase
1	Akurasi (AC)	0.2984	29.84%
2	<i>True positive rate</i> (TP)	0.518	51.8%
3	<i>False negative rate</i> (FN)	0.482	48.2%
4	<i>False positive rate</i> (FP)	0.7175	71.75%
5	<i>True negative rate</i> (TN)	0.2825	28.25%
6	Presisi (P)	0.0499	4.99%

Tabel 6 Hasil penilaian percobaan 2

IV. KESIMPULAN

A. Kesimpulan

Dari hasil uji coba yang telah dilakukan dapat diambil beberapa kesimpulan sebagai berikut:

1. Metode Mahalanobis *Distance* tidak dapat digunakan untuk mengklasifikasikan antara paket data normal dan paket data yang berupa intrusi untuk protokol HTTP. Jarak yang dihasilkan pada saat *training* menggunakan paket data normal maupun paket data yang berupa intrusi yaitu

bernilai 0. Sehingga paket data normal maupun paket data intrusi tidak dapat dibedakan.

2. Sistem yang dibuat untuk mendeteksi intrusi menggunakan metode Mahalanobis Distance tanpa proses *incremental learning* dapat mendeteksi intrusi dengan persentase kebenaran sekitar 93%, namun dengan tambahan proses *incremental learning* hanya dapat mendeteksi intrusi dengan persentase kebenaran sekitar 20%. Dari hasil tersebut, dengan tambahan proses *incremental learning* mengurangi tingkat akurasi pendeteksian intrusi.

B. Saran

Adapun saran-saran yang diberikan adalah penggunaan metode mahalanobis distance dengan proses *incremental learning* untuk membedakan paket data normal dengan paket data serangan kurang akurat dibandingkan tanpa penambahan proses *incremental learning*. Hal ini dikarenakan dengan menambahkan proses *incremental learning*, rata-rata dan standar deviasi pada model akan diperbaharui, akan tetapi threshold yang digunakan untuk mendeteksi intrusi tidak diperbaharui, yang mengakibatkan threshold yang ada tidak akurat untuk mendeteksi intrusi. Perlu ada implementasi metode lain sehingga dapat membantu meningkatkan keakuratan pendeteksian intrusi.

DAFTAR PUSTAKA

- [1] SANS Institute, "Understanding Intrusion Detection System," *SANS Institute Reading Room*, pp. 1-9, 2001.
- [2] "Intrusion detection system," [Online]. Available: https://en.wikipedia.org/wiki/Intrusion_detection_system. [Diakses 22 June 2016].
- [3] S. J. S. Ke Wang, "Anomalous Payload-based Network Intrusion Detection".
- [4] A. Hanafi, "Pengenalan Bahasa Suku Bangsa Indonesia Berbasis Teks Menggunakan Metode N-gram. IT TELKOM," 2009.
- [5] "Mahalanobis distance," [Online]. Available: https://en.wikipedia.org/wiki/Mahalanobis_distance. [Diakses 22 June 2016].
- [6] D. E. Knuth, "The Art of Computer Programming," *Fundamental Algorithms*. Addison Wesley, vol. 1, 1973.
- [7] K. Fuji, "a Java library for capturing and sending network packets," Jpcap, 15 May 2007. [Online]. Available: <http://jpcap.gitspot.com/>. [Diakses 23 May 2016].
- [8] V. Galleys, "Cross Validation," 2006. [Online]. Available: http://www.cse.iitb.ac.id/~tarung/smt/papers_ppt/ency-cross-validation.pdf. [Diakses 24 June 2016].
- [9] MIT Lincoln Laboratory, "MIT Lincoln Laboratory: Cyber system& technolog: DARPA Intrusion Detection," MIT Lincoln Laboratory, [Online]. Available: <https://www.ll.mit.edu/mission/communications/cyber/CSTcorpora/ideval/docs/index.html>. [Diakses 23 Mei 2016].
- [10] Kohavi, "Confusion Matrix," 1999. [Online]. Available: http://www2.cs.uregina.ca/~dbd/cs831/notes/confusion_matrix/confusion_matrix.html. [Diakses 24 June 2016].